


Léa YOUSSEF Arnaud MAGARIAN Guilhem MAILLEBUAU Marie-Alix HONORÉ Yasmina BENDAOUD

Livrable 4 - Développement d'application Cloud

Application cloud



07/11/2020

Table des matières

Table des matières	2
Dénormalisation "_id" : {'year', 'country'}	3
Importation des données	4
Mesure de performances	5
Requêtes :	5
Requête 1 :	5
Requête 2 :	5
Requête 3 :	5
Requête 4 :	6
Requête 5	7
Requête 6 :	7
Requête 7	8
Requête 8 :	9
Mesure des temps d'exécution :	13
Vues	16
O. Page d'accueil	16
1. Utilisateur Standard	17
2. Analyste / Décisionnaire	19
3. Administrateur	28
Code	32

I. Dénormalisation "_id" : {'year', 'country'}

```
{
       "_id": { "year" : 2010 , "Country_name" : "France"}
       "country_stats":
               "Country area" : 652230,
               "Crude_birth_rate": 45.96,
                              "Crude death rate": 18.73,
                              "Net migration": -9.88,
                              "Rate_natural_increase": 2.723,
                              "Growth rate": 1.735,
                              "Fertility_rate_15-19": 124.2,
               "Fertility rate 20-24": 291.9,
               "Fertility_rate_25-29": 328.1,
"Fertility_rate_30-34": 277,
               "Fertility_rate_35-39": 218.4,
"Fertility_rate_40-44": 129.2,
               "Fertility_rate_45-49": 71.2,
               "total_fertility_rate": 7.2,
               "gross_reproduction_rate": 3.5122,
               "sex_ratio_at_birth": 1.05,
               "Midyear_population": 22507460,
               "Infant mortality": 22507460,
               "Life expectancy": 45.81,
               "Mortality_rate_under5": 216.56,
               "Mortality_rate_1to4": 83.94,
               "Flag": [ {
                                      "total flag": [A,*],
                       "Starting age": 9,
                       "Ending_age": 15,
                       "Age_group_indicator": [+,-],
                       "Midyear_population_male": 1104463,
"Midyear_population_female": 1055773,
                       "Midyear population": 2160236,
               } ]
                      "Male":{
                      "Infant_mortality_male": 153.37, "Life_expectancy_male": 44.85,
                       "Mortality_rate_under5_male": 222.96,
                       "Mortality_rate_1to4_male": 82.20,
                       "Max age": 100,
                       "Population age 0": 64496,
                       "Population age 100": 0,
               }
                        "Female"{
                       "Infant_mortality_female": 135.74,
                       "Life expectancy female": 46.83,
                       "Mortality rate under5 female": 209.84,
                       "Mortality_rate_1to4_male": 85.74,
                       "Max age": 100,
                       "Population_age_0": 25166,
                       "Population_age_100": 8484,
               }
       }
}
```

II. Importation des données

Afin de dénormaliser le dataset en respectant le schéma produit dans le 2ème livrable, nous avons développé un script python permettant, à partir des fichiers au format csv, de créer un unique fichier json. L'objectif de ce script était de rassembler toutes les informations dans une structure logique dans un dataframe.

Lors de l'importation de nos différents fichiers csv, nous avons procédé à un data cleaning, dans le but de conserver uniquement les informations intéressantes pour nos requêtes. Nous avons donc supprimé la colonne "country code".

Nous avons fait le choix de négliger la table midyear_population_age_country car c'est une permutation de la table midyear_population_age_sex et d'une autre table que nous n'avons pas.

Nous avons rassemblé toutes nos données importées dans des dataframe dans un unique dataframe. Nous avons mergé les bases de données avec des outer-join sur les attributs country_name et year.

Ensuite, nous avons créé plusieurs listes:

- "flags": qui contient un tableau de flag pour chaque pays/année/sexe
- "sexe": qui contient deux tableaux avec les attributs correspondants à "Male" et "Female" pour respecter notre schéma de dénormalisation.

→ regrouper les deux informations "Male" et "Female" dans un même tableau nous permet d'obtenir un Dataframe ou chaque ligne correspond à [1 pays+1 année].

En parallèle, nous avons réalisé des modifications comme le passage de variables en variables de type str, le changement des virgules en points, etc.

Nous avons finalement créé des fonctions qui parcourent ce dataframe et ses tableaux pour générer un fichier json de 23080 documents.

Ensuite, dans Studio 3T, nous avons créé la base de données countrybase et des collections qui nous permettent d'appliquer les requêtes.

voir dénormalisation dans dossier.

III. Mesure de performances

Requêtes:

Nous avons explicité nos 8 questions sous forme de requêtes sur MongoDB.

• Requête 1:

```
db.year_key.find({"_id.year": "2020", "country_stats.life_expectancy" : {$ne :
"null"} }).sort({"country_stats.life_expectancy": -1}).limit(1)

• Requête 2:

db.Year_Key.aggregate([{$match : {"_id.year" : "2020"}},{$project :
{"_id.country_name": 1, "pop_km2" : { "$divide": [{$toDecimal:
"$country_stats.midyear_population"},
{$toDecimal:"$country_stats.country_area"}]}}]);
```

Les requêtes suivantes utilisent toutes map reduce.

• Requête 3:

```
var map2 = function(){
    if(this._id.year == "1955" || this._id.year == "1950")
        if( this.country_stats.crude_birth_rate != "null")
            emit(this. id.country name, {"years":[{year : this. id.year,
crude birth rate : this.country stats.crude birth rate}], diff:null });}
var reduce2 = function(key, values) {
   y = {"years":[]};
   va155 = 0;
   va150 = 0;
   for(i =0; i<values.length;i++)</pre>
       for(j=0; j<values[i].years.length ; j++){</pre>
           if(values[i].years[j].year == "1950") val50 =
values[i].years[j].crude birth rate;
           if(values[i].years[j].year == "1955") val55 =
values[i].years[j].crude birth rate;
           y.years.push(values[i].years[j]); }
      if(val55 > 0 \& val50 > 0)
      y.diff = val55 - val50;
       else
               y.diff = null;
       return y; };
var queryParam2 ={ query: {},out: "map reduce baby boom"};
db.year_key.mapReduce(
             map2,
             reduce2,
             queryParam2)
db.map reduce baby boom.find({"value.diff" : {"$gte" : 0.1}});
```

• Requête 4:

```
var map4 = function(){
    if(this. id.country name == "Iraq" || this. id.country name == "United States"
        if(parseInt(this. id.year) > 1999 & parseInt(this. id.year) < 2016)</pre>
            if(this.country_stats.crude_birth_rate != "null" &&
this.country_stats.crude_death_rate != "null")
                emit(this._id.country_name, {"years":[{year : this._id.year,
crude_birth_rate : this.country_stats.crude_birth_rate, crude_death_rate :
this.country_stats.crude_death_rate, diff: null}] }); };
var reduce4 = function(key, values){
   y = {"years":[]};
   for(i =0; i<values.length;i++)</pre>
       for(j=0; j<values[i].years.length ; j++)</pre>
           values[i].years[j].diff = values[i].years[j].crude birth rate -
values[i].years[j].crude death rate;
           y.years.push(values[i].years[j])
    return y ; };
db.year key.explain("executionStats").mapReduce(
        map4,
        reduce4, {
            query: {},
            out: "map_reduce_impact_irak" }
db.map reduce impact irak.find();
```

• Requête 5

```
var map5 = function(){
    if((this. id.year =="2020" || this. id.year == "2010") &&
this.country_stats.crude_birth_rate!=null )
        emit(this._id.country_name, {"years":[{year : this._id.year,
crude_birth_rate : this.country_stats.crude_birth_rate}], diff:null}); };
var reduce5 = function(keyCountry, values) {
   y = {"years":[]};
   va155 = 0;
   va150 = 0;
   for(i =0; i<values.length;i++)</pre>
       for(j=0; j<values[i].years.length ; j++){</pre>
           if(values[i].years[j].year == "2020") val55 =
values[i].years[j].crude birth rate;
           if(values[i].years[j].year == "2010") val50 =
values[i].years[j].crude birth rate;
           y.years.push(values[i].years[j]);
    if(val55 > 0 && val50 > 0)
       y.diff = val55 - val50;
    else
        y.diff = null;
   return y; }
db.Year Key.mapReduce(
      map5,
      reduce5, {
             query: {},
             out: "map reduce max increase" })
db.map reduce max increase.find().sort({"value.diff":-1}).limit(1)
```

• Requête 6:

```
var map6 = function(){
    if(parseInt(this._id.year) > 2010 && parseInt(this._id.year) < 2021)</pre>
        if (this.country stats.rate natural increase != "null")
            emit(this. id.country name, {"years":[{year : this. id.year,
natural rate : parseFloat(this.country stats.rate natural increase), population :
this.country_stats.midyear_population}], avg_evolution:null, pop_decroiss :
null});
var reduce6 = function(key, values)
   y = {"years":[]};
   val19 = 0;
   val20 = 0;
   sum natural rate = 0;
   count = 0;
   for(i =0; i<values.length;i++)</pre>
       for(j=0; j<values[i].years.length ; j++){</pre>
           if(values[i].years[j].year == "2019") val19 =
values[i].years[j].population;
           if(values[i].years[j].year == "2020") val20 =
values[i].years[j].population;
           if(values[i].years[j].natural_rate != null)
               sum natural rate += values[i].years[j].natural rate;
               count ++;
           y.years.push(values[i].years[j]);
```

```
if(sum natural rate != 0)
        y.avg evolution = sum natural rate/count;
        y.avg evolution = null;
    if(val19 > 0 \&\& val20 > 0)
        if(val20 - val19 < 0)
            y.pop_decroiss = "Décroissante";
        else
            y.pop_decroiss = "Croissante";
    else
        y.pop_decroiss = null;
   return y;
};
var queryParam6 ={ query: {},out: "map reduce baby boom"};
db.year key.mapReduce(
             map6,
             reduce6,
             queryParam6
db.map reduce baby boom.find({"value.avg evolution" : {$ne :
null}}).sort({"value.avg evolution":1}).limit(10);
   • Requête 7
var map7 = function()
    if(this.country_stats.mortality_rate_under5 != "null" )
        emit(this. id.year, {"countries" :[{country : this. id.country name, mru
:this.country stats.Male.infant mortality male }] ,count:null});
};
var reduce7 = function(key, values)
    y = {"countries":[]}
   var country count = 0
    for(i =0; i< values.length; i++) {</pre>
        if(values[i].countries !=null) {
            for(j=0; j<values[i].countries.length ; j++) {</pre>
                if(parseFloat(values[i].countries[j].mru) >100.0) {
                    country count = country count +1
                    y.countries.push(values[i].countries[j]) } }
    y.count = country count
    return y; };
db.year_key.mapReduce(
       map7,
        reduce7,
            query: {},
            out: "map reduce max increase"
        }
```

db.map reduce max increase.find().sort({" id.year":-1});

• Requête 8:

```
var map8 = function()
  if(this. id.country name == "France")
    emit(this._id.year, {"populations":[{male_pop: this.country_stats.Male, female_pop:
this.country stats.Female }],max: null}); };
var reduce8 = function(key, values){
  y = {"populations":[]}
  index = [];
 for(i =0; i< values.length; i++)
    if(values[i].populations !=null)
      for(j=0; j<values[i].populations.length; j++)
        if (values[i].populations[j] !=null)
           max = 0.0;
           if (values[i].populations[j].male pop != null & values[i].populations[j].female pop != null)
           y.populations.push(values[i].populations[j]);
           index.push(parseFloat(values[i].populations[j].male pop.population age 0) +
parseFloat(values[i].populations[j].female pop.population age 0))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_1) +
parseFloat(values[i].populations[i].female pop.population age 1))
           index.push(parseFloat(values[i].populations[j].male pop.population age 2) +
parseFloat(values[i].populations[j].female pop.population age 2))
           index.push(parseFloat(values[i].populations[j].male pop.population age 3) +
parseFloat(values[i].populations[j].female pop.population age 3))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_4) +
parseFloat(values[i].populations[j].female pop.population age 4))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_5) +
parseFloat(values[i].populations[j].female pop.population age 5))
           index.push(parseFloat(values[i].populations[j].male pop.population age 6) +
parseFloat(values[i].populations[j].female pop.population age 6))
           index.push(parseFloat(values[i].populations[j].male pop.population age 7) +
parseFloat(values[i].populations[i].female pop.population age 7))
           index.push(parseFloat(values[i].populations[j].male pop.population age 8) +
parseFloat(values[i].populations[j].female_pop.population_age_8))
           index.push(parseFloat(values[i].populations[j].male pop.population age 9) +
parseFloat(values[i].populations[j].female pop.population age 9))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_10) +
parseFloat(values[i].populations[j].female pop.population age 10))
           index.push(parseFloat(values[i].populations[j].male pop.population age 11) +
parseFloat(values[i].populations[j].female pop.population age 11))
           index.push(parseFloat(values[i].populations[j].male pop.population age 12) +
parseFloat(values[i].populations[j].female pop.population age 12))
           index.push(parseFloat(values[i].populations[j].male pop.population age 13) +
parseFloat(values[i].populations[j].female pop.population age 13))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_14) +
parseFloat(values[i].populations[j].female pop.population age 14))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_15) +
parseFloat(values[i].populations[j].female_pop.population_age_15))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_16) +
parseFloat(values[i].populations[j].female pop.population age 16))
           index.push(parseFloat(values[i].populations[j].male pop.population age 17) +
parseFloat(values[i].populations[j].female pop.population age 17))
```

```
index.push(parseFloat(values[i].populations[j].male_pop.population_age_18) +
parseFloat(values[i].populations[j].female pop.population age 18))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_19) +
parseFloat(values[i].populations[j].female_pop.population_age_19))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_20) +
parseFloat(values[i].populations[j].female_pop.population_age_20))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_21) +
parseFloat(values[i].populations[j].female pop.population age 21))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_22) +
parseFloat(values[i].populations[j].female pop.population age 22))
           index.push(parseFloat(values[i].populations[j].male pop.population age 23) +
parseFloat(values[i].populations[j].female_pop.population_age_23))
           index.push(parseFloat(values[i].populations[j].male pop.population age 24) +
parseFloat(values[i].populations[j].female pop.population age 24))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_25) +
parseFloat(values[i].populations[j].female pop.population age 25))
           index.push(parseFloat(values[i].populations[j].male pop.population age 26) +
parseFloat(values[i].populations[j].female pop.population age 26))
           index.push(parseFloat(values[i].populations[j].male pop.population age 27) +
parseFloat(values[i].populations[j].female pop.population age 27))
           index.push(parseFloat(values[i].populations[j].male pop.population age 28) +
parseFloat(values[i].populations[j].female pop.population age 28))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_29) +
parseFloat(values[i].populations[j].female pop.population age 29))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_30) +
parseFloat(values[i].populations[j].female pop.population age 30))
           index.push(parseFloat(values[i].populations[j].male pop.population age 31) +
parseFloat(values[i].populations[j].female pop.population age 31))
           index.push(parseFloat(values[i].populations[j].male pop.population age 32) +
parseFloat(values[i].populations[j].female pop.population age 32))
           index.push(parseFloat(values[i].populations[j].male pop.population age 33) +
parseFloat(values[i].populations[j].female pop.population age 33))
           index.push(parseFloat(values[i].populations[j].male pop.population age 34) +
parseFloat(values[i].populations[j].female_pop.population_age_34))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_35) +
parseFloat(values[i].populations[j].female pop.population age 35))
           index.push(parseFloat(values[i].populations[j].male pop.population age 36) +
parseFloat(values[i].populations[j].female pop.population age 36))
           index.push(parseFloat(values[i].populations[i].male pop.population age 37) +
parseFloat(values[i].populations[j].female pop.population age 37))
           index.push(parseFloat(values[i].populations[j].male pop.population age 38) +
parseFloat(values[i].populations[j].female pop.population age 38))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_39) +
parseFloat(values[i].populations[j].female_pop.population_age_39))
           index.push(parseFloat(values[i].populations[j].male pop.population age 40) +
parseFloat(values[i].populations[j].female pop.population age 40))
           index.push(parseFloat(values[i].populations[j].male pop.population age 41) +
parseFloat(values[i].populations[j].female pop.population age 41))
           index.push(parseFloat(values[i].populations[j].male pop.population age 42) +
parseFloat(values[i].populations[j].female pop.population age 42))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_43) +
parseFloat(values[i].populations[j].female_pop.population_age_43))
           index.push(parseFloat(values[i].populations[j].male pop.population age 44) +
parseFloat(values[i].populations[j].female_pop.population_age_44))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_45) +
parseFloat(values[i].populations[j].female pop.population age 45))
```

```
index.push(parseFloat(values[i].populations[j].male_pop.population_age_46) +
parseFloat(values[i].populations[j].female pop.population age 46))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_47) +
parseFloat(values[i].populations[j].female_pop.population_age_47))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_48) +
parseFloat(values[i].populations[j].female_pop.population_age_48))
           index.push(parseFloat(values[i].populations[j].male pop.population age 49) +
parseFloat(values[i].populations[j].female pop.population age 49))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_50) +
parseFloat(values[i].populations[j].female pop.population age 50))
           index.push(parseFloat(values[i].populations[j].male pop.population age 51) +
parseFloat(values[i].populations[j].female_pop.population_age_51))
           index.push(parseFloat(values[i].populations[j].male pop.population age 52) +
parseFloat(values[i].populations[j].female pop.population age 52))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_53) +
parseFloat(values[i].populations[j].female pop.population age 53))
           index.push(parseFloat(values[i].populations[j].male pop.population age 54) +
parseFloat(values[i].populations[j].female pop.population age 54))
           index.push(parseFloat(values[i].populations[j].male pop.population age 55) +
parseFloat(values[i].populations[j].female pop.population age 55))
           index.push(parseFloat(values[i].populations[j].male pop.population age 56) +
parseFloat(values[i].populations[j].female pop.population age 56))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_57) +
parseFloat(values[i].populations[j].female pop.population age 57))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_58) +
parseFloat(values[i].populations[j].female pop.population age 58))
           index.push(parseFloat(values[i].populations[j].male pop.population age 59) +
parseFloat(values[i].populations[j].female pop.population age 59))
           index.push(parseFloat(values[i].populations[j].male pop.population age 60) +
parseFloat(values[i].populations[j].female pop.population age 60))
           index.push(parseFloat(values[i].populations[j].male pop.population age 61) +
parseFloat(values[i].populations[j].female pop.population age 61))
           index.push(parseFloat(values[i].populations[j].male pop.population age 62) +
parseFloat(values[i].populations[j].female_pop.population_age_62))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_63) +
parseFloat(values[i].populations[j].female pop.population age 63))
           index.push(parseFloat(values[i].populations[j].male pop.population age 64) +
parseFloat(values[i].populations[j].female pop.population age 64))
           index.push(parseFloat(values[i].populations[i].male pop.population age 65) +
parseFloat(values[i].populations[j].female pop.population age 65))
           index.push(parseFloat(values[i].populations[j].male pop.population age 66) +
parseFloat(values[i].populations[j].female pop.population age 66))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_67) +
parseFloat(values[i].populations[j].female_pop.population_age_67))
           index.push(parseFloat(values[i].populations[j].male pop.population age 68) +
parseFloat(values[i].populations[j].female pop.population age 68))
           index.push(parseFloat(values[i].populations[j].male pop.population age 69) +
parseFloat(values[i].populations[j].female pop.population age 69))
           index.push(parseFloat(values[i].populations[j].male pop.population age 70) +
parseFloat(values[i].populations[j].female pop.population age 70))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_71) +
parseFloat(values[i].populations[j].female_pop.population_age_71))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_72) +
parseFloat(values[i].populations[j].female_pop.population_age_72))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_73) +
parseFloat(values[i].populations[j].female pop.population age 73))
```

```
index.push(parseFloat(values[i].populations[j].male_pop.population_age_74) +
parseFloat(values[i].populations[j].female pop.population age 74))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_75) +
parseFloat(values[i].populations[j].female_pop.population_age_75))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_76) +
parseFloat(values[i].populations[j].female_pop.population_age_76))
           index.push(parseFloat(values[i].populations[j].male pop.population age 77) +
parseFloat(values[i].populations[j].female pop.population age 77))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_78) +
parseFloat(values[i].populations[j].female pop.population age 78))
           index.push(parseFloat(values[i].populations[j].male pop.population age 79) +
parseFloat(values[i].populations[j].female_pop.population_age_79))
           index.push(parseFloat(values[i].populations[j].male pop.population age 80) +
parseFloat(values[i].populations[j].female pop.population age 80))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_81) +
parseFloat(values[i].populations[j].female pop.population age 81))
           index.push(parseFloat(values[i].populations[j].male pop.population age 82) +
parseFloat(values[i].populations[j].female pop.population age 82))
           index.push(parseFloat(values[i].populations[j].male pop.population age 83) +
parseFloat(values[i].populations[j].female pop.population age 83))
           index.push(parseFloat(values[i].populations[j].male pop.population age 84) +
parseFloat(values[i].populations[j].female pop.population age 84))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_85) +
parseFloat(values[i].populations[j].female pop.population age 85))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_86) +
parseFloat(values[i].populations[j].female pop.population age 86))
           index.push(parseFloat(values[i].populations[j].male pop.population age 87) +
parseFloat(values[i].populations[j].female pop.population age 87))
           index.push(parseFloat(values[i].populations[j].male pop.population age 88) +
parseFloat(values[i].populations[j].female pop.population age 88))
           index.push(parseFloat(values[i].populations[j].male pop.population age 89) +
parseFloat(values[i].populations[j].female pop.population age 89))
           index.push(parseFloat(values[i].populations[j].male pop.population age 90) +
parseFloat(values[i].populations[j].female_pop.population_age_90))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_91) +
parseFloat(values[i].populations[j].female pop.population age 91))
           index.push(parseFloat(values[i].populations[j].male pop.population age 92) +
parseFloat(values[i].populations[j].female pop.population age 92))
           index.push(parseFloat(values[i].populations[i].male pop.population age 93) +
parseFloat(values[i].populations[j].female pop.population age 93))
           index.push(parseFloat(values[i].populations[j].male pop.population age 94) +
parseFloat(values[i].populations[j].female pop.population age 94))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_95) +
parseFloat(values[i].populations[j].female_pop.population_age_95))
           index.push(parseFloat(values[i].populations[j].male pop.population age 96) +
parseFloat(values[i].populations[j].female pop.population age 96))
           index.push(parseFloat(values[i].populations[j].male pop.population age 97) +
parseFloat(values[i].populations[j].female pop.population age 97))
           index.push(parseFloat(values[i].populations[j].male pop.population age 98) +
parseFloat(values[i].populations[j].female pop.population age 98))
           index.push(parseFloat(values[i].populations[j].male_pop.population_age_99) +
parseFloat(values[i].populations[j].female_pop.population_age_99))
           index.push(parseFloat(values[i].populations[i].male pop.population age 100) +
parseFloat(values[i].populations[j].female_pop.population_age_100))
  var i = index.indexOf(Math.max(...index));
 y.max = i;
```

```
return y; };
db.year_key.mapReduce(
    map8,
    reduce8,
    {
        query: {},
        out: "map_reduce_fr_most_represented_age_group"
      }
    )
db.map reduce fr most represented age group.find({"value.max" : {$ne :-1.0}});
```

Mesure des temps d'exécution :

Afin de calculer le temps d'exécution, nous avons utilisé un tableau Excel pour faire les calculs (voir ci-dessous).

Pour chaque requête, pour les 6 shards, nous avons noté le temps d'exécution pour chaque réplicaset.

Nous en avons ensuite fait la somme, et nous avons répété l'opération 10 fois de suite.

Enfin, nous avons calculé la moyenne sur ces 10 valeurs en retirant la valeur minimale et maximale (tableau de droite).

Nous avons répété l'opération en retirant un shard c'est-à-dire que nous avons calculé le temps avec une répartition sur 5 shards, puis 4 shards, puis 3 shards etc... jusqu'à tester sur 1 shard.

								Temps	d'éxecu	ition								
								Répartiti	on sur 6 sl	hards								
	Somme de	s temps d'ex	écution en N	tillis des share	is pars requête							Calcul d	e la moyenn	e sur 10 itéra	tions			
Requête -shards	1	2	3	4	5	6 Sor	nme	1 2	1		-	6	7		9	10		Noyenne(total-min-max)
R1	1232,0						1232,0	1232,00	26,00	3,00	3,00	2,00	3,00	2,00	2,00	2,00	3,00	5,50
R2	0,0						0,0	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
R3	45,0	49,0	49,0	53,0	62,0	71,0	330,0	327,00	316,00	327,00	312,00	319,00	325,00	315,00	326,00	320,00	330,00	321,88
R4	30,0	41,0	48,0	57,0	62,0	76,0	314,0	329,00	332,00	327,00	324,00	336,00	343,00	331,00	317,00	316,00	314,00	326,50
R5	37,0	37,0	53,0	54,0	62,0	90,0	333,0	339	338	340	348	338	348	332	342	350	333	340,75
R6	36,0	46,0	50,0	57,0	68,0	143,0	400,0	376	413	392	388	395	403	388	399	394	400	394,88
R7	45,0	65,0	69,0	125,0	139,0	169,0	612,0	602	605	600	585	581	600	593	618	602	612	599,88
R8	43,0	48,0	63,0	70,0	86,0	95,0	405,0	6651,00	392,00	395,00	405,00	399,00	409,00	429,00	402,00	394,00	405,00	404,75
								Répartiti	on sur 5 sl	hards								
	Somme de	s temps d'ex	écution en N	tillis des share	is pars requête							Calcul d	e la moyenn	e sur 10 itéra	tions			
Requête -shards	1	2	3	4	5	6 Soi	nme	1 2	6		6	6	7		9	10		
R1							0,0	4,00	6,00	4,00	3,00	4,00	4,00	4,00	5,00	5,00	5,00	4,38
R2							0,0	1,00	1,00	0,00	0,00	0,00	1,00	1,00	1,00	1,00	1,00	0,75
R3	46,0	47,0	66,0	64,0	68,0		291,0	310,00	307,00	304,00	300,00	311,00	312,00	299,00	302,00	301,00	291,00	304,25
R4	43,0	53,0	66,0	72,0	77,0		311,0	258,00	309,00	309,00	309,00	302,00	302,00	302,00	315,00	318,00	310,00	307,25
R5	41,0	47,0	64,0	65,0	77,0		294,0	307	315	321	320	330	333	307	301	299	294	312,50
R6	49,0	50,0	63,0	68,0	117,0		347,0	351	362	377	350	349	349	347	335	358	347	351,63
R7	46,0	79,0	138,0	157,0	169,0		589,0	553	554	564	547	549	568	566	564	567	589	560,63
R8	49,0	54,0	85,0	91,0	100,0		379.0	396,00	383.00	385.00	376.00	369.00	390.00	370.00	386.00	396,00	379.00	383.13

Visualisation du tableau de coût pour 6 shards et 5 shards (le fichier excel contenant l'intégralité est dans le dossier du projet)


Observations et explications :

<i>y</i>					
Moyenne(total-min -	Moyenne(total-min -	loyenne(total-min -	Moyenne(total-min -		
5,50	4,38	4,38	4,13		
0,00	0,75	0,75	1,00		
321,88	304,25	279,75	266,13		
326,50	307,25	272,25	258,00		
340,75	312,50	294,00	275,13		
394,88	351,63	331,00	316,13		
599,88	560,63	535,13	507,13		
404,75	383,13	358,13	319,75		
2394,13	2224,50	2075,38	1947,38		
[loyenne(total-min -			
	4,13	4,38			
	1,00	1,00			
	233,00	200,38			
	242,88	195,25			
	260,25	208,38			
	293,88	243,25			
	499,38	412,63			
	304,75	267,25			
	1839,25	1532,50			

Pour chaque configuration, après avoir calculé le temps moyen au bout de 10 répétitions, nous avons additionné les différents temps moyen trouvés.

Nous pouvons constater qu'à mesure que le nombre de shards diminue, le temps d'exécution des requêtes diminue lui aussi fortement.

Ci-dessous : Une représentation graphique de la durée d'exécution des requêtes en fonction de celles-ci et du nombre de shards:



On voit que les courbes pour un même nombre de shards suivent la même tendance. Le temps d'exécution est constant pour les deux premières requêtes qui sont simples et dont les données sont réparties sur un shard uniquement. Ce qui est la raison principale d'un temps d'exécution si bas.

Le temps d'exécution augmente beaucoup plus pour la requête 3 qui a besoin d'un coût plus élevé car les données sont répartis sur les 6 shards.

Globalement, l'allure continue d'augmenter avec les requêtes, on remarque une nette augmentation de coût pour la requête 7. La raison de ceci est que la requête va devoir appeler l'intégralité des shards pour ensuite réaliser un shuffle globale.

Comme précisé précédemment, pour une requête donnée, le temps d'exécution est plus élevé quand le nombre de shards augmente. Ce qui est compréhensible, car les données sont répartie sous différents shards et nécessite d'autant plus de coût réseau.

IV. Vues

Pour le développement de cette application, nous avons choisi Python et Django, pour la partie web et aussi pour la connexion à la base de données MongoDB en SSH.

Il y a 3 vues principales, une pour chaque type d'utilisateur et une vue pour la page d'accueil de notre application. Chaque utilisateur peut exécuter une liste de requêtes correspondant à son poste.

Le fichier urls.py contient une liste de chemins d'accès permettant de lier un URL à une fonction du fichier views.py.


Dans le fichier views.py, on retrouve les diverses fonctions correspondant à nos différentes requêtes. Ces différentes fonctions retournent un HTML ainsi que les données que nous a retourné notre requête. Pour chaque fonction de requête on trouve un fichier HTML pour une vue adaptée.

On trouve aussi une fonction permettant de se connecter en SSH à notre base donnée ainsi que deux fonctions permettant de générer des graphs pour ensuite les afficher dans nos pages HTML.

0. Page d'accueil

Cette page permet d'accueillir le visiteur de l'application et propose le choix entre 3 boutons: <u>Utilisateur standard</u>, <u>Utilisateur Décisionnaire</u> et <u>Administrateur</u>.


Ensuite, chaque vue est adaptée à ce que peut faire ou voir le visiteur et comporte les fonctionnalités associées, détaillées dans les parties suivantes



Page d'Accueil de l'application

1. Utilisateur Standard

Cet utilisateur peut accéder au 4 requêtes simples et voir le contenu des données à travers l'affichage.




Page Utilisateur Standard


Grâce à des sélections sur le côté gauche, l'utilisateur standard peut avoir accès aux 4 requêtes simples et sur la droite, il peut voir les questions associées.

L'accès à chaque requête lui affiche la question associée à celle-ci ainsi qu'une phrase qui lui affiche le résultat, après s'être au préalable connecté à la base de données.


Il peut aussi mettre la souris sur "Profil", un sous menu s'affiche alors pour proposer de changer de statut.




Bouton Requête 1



Bouton Requête 2



Bouton Requête 3




Bouton Requête 4

2. Analyste / Décisionnaire


Le Data Analyst ou Business User a accès aux requêtes complexes proposées.

L'interface devra permettre de paramétrer les requêtes avec des valeurs par menu déroulant.

Si l'utilisateur choisit l'option "Analayste Décisionnaire", il arrive sur cette page :




Il peut alors consulter les 4 requêtes difficiles depuis le menu.




Bouton Requête 5


Pour cette requête, l'analyste peut paramétrer la requête en choisissant la période à appliquer.




Résultat de 5) pour la sélection "2000-2010"




Résultat de 5) pour la sélection "2010-2020"




Résultat de 5) pour la sélection "2000-2020"




Choix du top pour 6)




Choix du top 10 pour 6)



Choix du top 20 pour 6)




Choix du top 50 pour 6)




Choix du taux pour 7)




Choix d'un taux de 80 pour 7)




Choix d'un taux de 100 pour 7)




Choix d'un taux de 150 pour 7)




Choix du pays pour 8)



Choix de la France pour 8)



Choix de l'Afghanistan pour 8)



Choix du Mexique pour 8)


3. Administrateur

L'administrateur de la base MongoDB doit pouvoir récupérer différentes statistiques pour pouvoir faire évoluer le cluster en fonction de la charge. La vue doit pouvoir fournir les informations suivantes :

- Les statistiques de distribution des données ;
- Consulter l'état du cluster : nombre de shards, nombre de réplicats par shard
- Répartition des données sur les shards (nombre de documents)
- Indexes existants sur les données

Après avoir fait le calcul de coûts , notre configuration est positionnée sur un seul shard . De ce fait l'ensemble des données est situé le shard RS1MX. Nous avons laissé cette configuration pour bien mettre en valeur la différence de répartition des documents dans le cluster pour la partie administrateur.


Pour revenir à une configuration distribué c'est-à-dire sur 6 shards, nous devons rajouté des shards via la commande mongo.




Arrivé sur la page administrateur, le menu propose encore de retourner au profil et d'accéder aux options suivantes :

- Statistiques : consulter les statistiques de distribution
- Etat : voir l'état du cluster c'est à dire le nombre de shards, nous n'avons pas de réplicaset
- Répartition : répartition des données sur les shards (nombres de documents par shard)
- Indexes : voir les indexes sur les données







V. Code

Le code de l'application est disponible sur Github.

Lien github: https://github.com/leyousse/DevAppCloud

Vous pouvez consulter une vidéo de l'application intitulée Démonstration_application.mp4 dans le lien suivant :

https://drive.google.com/drive/folders/1AMVIATfN0rfaP_I8FkAdScsMrXZ-p0LS?usp =sharing